

Exercício 1 de Análise de Dados

Entrega: 29/08/2026

Apresentação: 31/08/2026

Para viabilizar a execução prática sem a necessidade de baixar 10 arquivos CSV externos, cada projeto abaixo inclui um **script Python completo de geração sintética**. Esses scripts geram um DataFrame limpo, introduzem intencionalmente ruídos (nulos, *outliers*, desbalanceamentos temporários) e devolvem a base pronta para a aula, além de fornecer um pequeno conjunto final de **Novos Dados (Inéditos)** para os alunos realizarem as previsões (predict e predict_proba).

Módulo de Geração Global (Utilitário para os Grupos)

Cada grupo pode rodar a função **gerar_dados()** contida no arquivo de cada projeto. Existe uma função **gerar_dados()** em cada arquivo de projeto, ou seja, projeto_01.py, projeto_02.py, projeto_03.py projeto_10.py.

No código disponibilizado nesta função, serão gerados **1.000 registros para o dataset de treino/teste** e **2 registros adicionais para os novos dados** em cada um dos 10 projetos. Cada grupo deverá gerar o seu projeto.

Para gerar cada projeto, faça o seguinte procedimento:

Crie um **arquivo .ipynb** no jupyter notebook ou no google Colaboratory com o nome do seu grupo, por exemplo, **grupo_01.ipynb**. Cada grupo deverá ter um arquivo com seu nome.

Crie a primeira célula do jupyter notebook do seu grupo com o seguinte código:

```
%run projeto_id.py
```

Crie segunda célula do jupyter notebook com o seguinte código:

1. Executa a função do projeto

```
df_treino, novos_dados = gerar_dados()
```

2. Exibe quantas linhas foram geradas no dataset principal

```
print("Tamanho do dataset principal:", df_treino.shape) # Retorna (1000, 5)
```

3. Exibe as 5 primeiras linhas do dataset principal

```
df_treino.head()
```

Projeto 1: Diagnóstico Preventivo de Complicações Cardíacas (Grupo 1)

Id=01

Grupo 1

Paulo
Gabriel Dias
Lucas
Moscofian
Matheus Lopes

- **Domínio:** Saúde Digital
- **Variáveis:** idade (int), pressao_arterial (float com outliers), eletro_resultado (string/nominal: "Normal", "Alterado", "Risco"), fumante (binário: "Sim"/"Não"), alvo (binário: 0/1).
- **Desafio:** Inferir pressao_arterial ausente por mediana; aplicar One-Hot no resultado do eletro; aplicar Label Encoding no status de fumante.

Projeto 2: Detecção de Risco de Cancelamento de Assinatura (SaaS Churn) (Grupo 2)

Id=02

Grupo 2

Ana Julia
Isabelly
Nathália
Anderson da
Silva

- **Domínio:** Tecnologia / Negócios
- **Variáveis:** dias_ativo (int), ticket_mensal (float com outliers), plano (string/ordinal: "Básico", "Intermediário", "Premium"), suporte_acionado (binário: "Sim"/"Não"), churn (binário: 0/1).
- **Desafio:** Imputação de ticket_mensal pela média condicional ao plano; Ordinal Encoding em plano.

Projeto 3: Concessão de Crédito Universitário (Grupo 3)

Id=03

Grupo 3

Renan
Valença
Maycon C.
Gustavo
Tenório
Luiz

- **Domínio:** Finanças
- **Variáveis:** renda_familiar (float com outliers), historico_inadimplencia (binário: "Possui"/"Não Possui"), nivel_escolaridade (string/ordinal: "Médio", "Graduação", "Pós"), idade (int), aprovado (binário: 0/1).

- **Desafio:** Tratar outliers de renda por truncamento IQR (Interquartile Range); Label Encoding na inadimplência.

Projeto 4: Predição de Fraude em Transações de E-commerce (Grupo 4)

Id=04

Grupo 4

Giovanni

Medici

Gaspar Silva

David Martins

Ryan Furtado

- **Domínio:** Segurança da Informação
- **Variáveis:** valor_transacao (float), horario_transacao (int), dispositivo (string/nominal: "Mobile", "Desktop", "WebTV"), biometria_validada (binário: "Sim"/"Não"), is_fraude (binário: 0/1).
- **Desafio:** One-Hot Encoding em dispositivo; Imputação por mediana em valor_transacao.

Projeto 5: Seleção de Candidatos para Vagas de Tecnologia (Grupo 5)

Id=05

Grupo 5

Camila

Pereira

Giovanna

Brandão

Artur

Miranda

- **Domínio:** Recursos Humanos
- **Variáveis:** anos_experiencia (int), nota_teste_tecnico (float), ingles (string/ordinal: "Básico", "Intermediário", "Avançado"), certificacao (binário: "Sim"/"Não"), hired (binário: 0/1).
- **Desafio:** Tratar notas zeradas discrepantes (*outliers* de medição); Ordinal Encoding do nível de inglês.

Projeto 6: Avaliação de Risco de Manutenção de Máquinas Industriais (Grupo 6)

Id=06

Grupo 6

Guilherme

Kayky

Lorena

Nicolly

- **Domínio:** Indústria 4.0 / IoT

- **Variáveis:** temperatura_motor (float), vibracao (float com outliers), tipo_combustivel (string/nominal: "Diesel", "Eletrico", "Hibrido"), revisao_em_dia (binário: "Sim"/"Não"), falha (binário: 0/1).
- **Desafio:** One-Hot Encoding em tipo_combustivel; Normalização MinMax das leituras de sensores.

Projeto 7: Engajamento e Eficiência de Estudantes EAD (Grupo 7)

Id=07

Grupo 7

Rafael Yukio
Kaian Muniz
Gabriel Trolezi
João Vitor
Souza

- **Domínio:** EdTech
- **Variáveis:** horas_estudo_semana (float), atividades_entregues (int), turno_preferencial (string: "Manhã", "Tarde", "Noite"), acesso_banda_larga (binário: "Sim"/"Não"), aprovado (binário: 0/1).
- **Desafio:** Tratamento de imputação em horas_estudo_semana; Padronização Z-Score.

Projeto 8: Eficiência na Entrega de Encomendas Urbanas (Grupo 8)

Id=08

Grupo 8

Maria Eduarda
M
Ramona P
Vitor Januario

- **Domínio:** Logística e Transportes
- **Variáveis:** distancia_km (float), tempo_entrega_min (float com outliers), veiculo (string: "Moto", "Bicicleta", "Carro"), clima_chuvoso (binário: "Sim"/"Não"), atrasou (binário: 0/1).
- **Desafio:** Remoção de *outliers* na variável de tempo; One-Hot Encoding no meio de transporte.

Projeto 9: Predição de Reassumo de Consumo de Energia Residencial (Grupo 9)

Id=09

Grupo 9

Reinaldo Henrique
Pedro Guedes

- **Domínio:** Utilities / Smart Grids
- **Variáveis:** kwh_mes (float com outliers), num_comodos (int), regioao_geografica (string: "Norte", "Sul", "Leste", "Oeste"), tarifa_social (binário: "Sim"/"Não"), alto_consumo (binário: 0/1).
- **Desafio:** Tratar nulos em kwh_mes; Imputação e aplicação de One-Hot Encoding para regioao_geografica.

Projeto 10: Priorização de Atendimento na Triagem Hospitalar (Grupo 10)

Id=10

Grupo 10

Gabriel
Ramaglia
Ian Souza

Victor vilas Boas

Pedro
Hardmann

- **Domínio:** Saúde Pública / Gestão Hospitalar
- **Variáveis:** frequencia_cardiaca (int), temperatura_c (float com outliers), sintoma_principal (string: "Dor Intensa", "Febre", "Enjoo", "Lesao Leve"), gestante (binário: "Sim"/"Não"), urgente (binário: 0/1).
- **Desafio:** Tratar ruídos na temperatura; One-Hot Encoding dos sintomas e Label Encoding da flag binária.